

SEANCE 4 • DONNEES

Preparation des donnees

Obtenir une base de travail propre avant de modeliser

Machine Learning • 15h • 10 seances de 1h30

Lewis Hounkpevi

Avant de nettoyer : cadrer

1

Problematique metier

Comprendre et formaliser le besoin.

2

Bases & variables

Datamap / dictionnaire des donnees.

3

Strategie d'analyse

Definir le plan de traitement.

Les etapes du nettoyage

- **Faire le point des variables** : type, role, signification.
- **Valeurs manquantes** : les detecter et les traiter.
- **Valeurs aberrantes** : outliers : erreurs ou valeurs reelles ?
- **Relations entre variables** : correlations, redondances.
- **Normalisation** : mettre les variables a la meme echelle.

Traiter les valeurs manquantes

Supprimer

- Lignes ou colonnes concernees
- Si peu de donnees touchees
- Attention a ne pas trop reduire
- Risque de biais

Imputer

- Moyenne / mediane (numerique)
- Mode (categoriel)
- Methode raisonnee metier
- Methodes plus sophistiquees

Valeurs extremes / aberrantes

- Detecter si c'est une erreur de saisie ou une vraie valeur.
- Si erreur : traiter comme une valeur manquante.
- Sinon : adopter une strategie adaptee (parfois normaliser).



Exemple

Un lyceen de 50 ans : aberration probable a investiguer, pas a supprimer aveuglement.

Selection des variables et du champ

Etape tres importante : garder ce qui est pertinent.

- **Sur les colonnes** : ecarter variables trop incompletes ou redondantes.
- **Eviter les biais** : ex. biais de selection des observations.
- **Sur les lignes** : supprimer les doublons, definir le champ d'etude.

Preparation des donnees

- ✓ Toujours cadrer la problematique metier avant de nettoyer.
- ✓ Nettoyer : manquantes, aberrantes, types, relations, normalisation.
- ✓ Imputer (moyenne/mediane/mode) ou supprimer avec parcimonie.
- ✓ Selectionner les bonnes variables = base de travail propre.