

SEANCE 5 • DONNEES

Analyse & visualisation

Comprendre les donnees avant de modeliser

Machine Learning • 15h • 10 seances de 1h30

Lewis Hounkpevi

Statistiques descriptives

Variables numeriques

- Moyenne, min, max
- Ecart-type
- Mediane
- Distribution

Variables categorielles

- Decompte des categories
- Mode
- Frequences
- Tableaux croises

Trouver les relations entre variables


Numerique <-> Numerique

- Table de correlation
- Coefficient de Pearson
- Nuages de points
- Detecter la redondance

Categoriel <-> Categoriel

- Test du chi2
- V de Cramer
- Tableaux de contingence
- Mesurer l'association

Lire une table de corrélation



Rouge = corrélation positive, bleu = négative ; |valeur| proche de 1 = lien fort.

A quoi sert la visualisation ?

Une bonne visualisation resume l'information.

- **Resumer** : synthetiser l'information contenue dans les donnees.
- **Relier** : presenter les relations entre variables.
- **Decider** : orienter les choix de traitement.
- **Anticiper** : entrevoir les resultats du modele.

Une viz utile, pas decorative

- Choisir le bon graphique selon le type de variable.
- Mettre en evidence l'essentiel, pas le superflu.
- Une visualisation doit clarifier, jamais complexifier.



Regle d'or

Si un graphique demande une longue explication, il a sans doute echoue.

A RETENIR

Analyse & visualisation

- ✓ Decrire : moyenne/ecart-type (num.), decomptes/mode (catégoriel).
- ✓ Relier : correlation (num.), χ^2 et V de Cramer (catégoriel).
- ✓ Visualiser pour resumer, relier, decider et anticiper.
- ✓ Une bonne viz clarifie l'information sans la complexifier.