

SEANCE 6 • FONDAMENTAUX

Les difficultes du ML

Pourquoi un projet echoue, et comment l'eviter

Machine Learning • 15h • 10 seances de 1h30

Lewis Hounkpevi

Les difficultes liees aux donnees

- **Echantillon non representatif** : modele non extrapolable (biais).
- **Donnees de mauvaise qualite** : valeurs aberrantes et manquantes.
- **Variables non pertinentes** : mauvaises features = mauvais modele.
- **Faible quantite de donnees** : impossible de generaliser.

Le feature engineering

- Conserver les variables pertinentes pour le meilleur modele.
- Selection des variables : garder les plus utiles.
- Extraction et collecte de nouvelles variables.




Coeur du metier de data scientist


De bonnes variables valent souvent mieux qu'un algorithme sophistique.

Sur-apprentissage vs sous-apprentissage


Sous-apprentissage



Bon modele



Sur-apprentissage



Trop simple : rate la tendance. Trop complexe : apprend le bruit. L'objectif est l'équilibre.

Comprendre les deux excès

Sur-apprentissage (overfitting)

- Modele trop complexe
- Apprend le bruit par coeur
- Excellent sur le train
- Mauvais sur le test

Sous-apprentissage (underfitting)

- Modele trop simple
- Rate la tendance
- Mauvais sur le train
- Mauvais sur le test

Comment corriger ?

Contre l'overfitting

- Simplifier le modele
- Plus de donnees d'apprentissage
- Reduire le bruit
- Regularisation

Contre l'underfitting

- Modele plus puissant
- De meilleures variables
- Moins de contraintes
- Plus de parametres

A RETENIR

Les difficultes du ML

- ✓ Le nerf de la guerre, ce sont les donnees, pas l'algorithmme.
- ✓ Risques : echantillon biaise, mauvaise qualite, features inutiles.
- ✓ Feature engineering : selectionner et creer de bonnes variables.
- ✓ Trouver l'equilibre entre sur- et sous-apprentissage.